# CONSTRUCCIÓN DE UN MODELO ESTADÍSTICO PARA PREDECIR LA MORTALIDAD DE PACIENTES CON INSUFICIENCIA CARDÍACA CONGESTIVA

*Eduardo García Alfonso, 2021*

El problema a plantear consistirá en predecir la probabilidad de fallecimiento en pacientes con insuficiencia cardíaca, en función de unas variables que pueden afectar al funcionamiento cardiovascular del individuo, utilizando métodos de estadística multivariante.

Los datos fueron obtenidos en la página *kaggle.com*, y se utilizó R como software estadístico.

# 1. ESTUDIO PREVIO DE LOS DATOS

## 1.1 LA BASE DE DATOS

Acerca de la base de datos (kaggle.com/andrewmvd, 2020):

> *Las enfermedades cardiovasculares (ECV) son la primera causa de muerte globalmente, llevándose aproximadamente 17.9 millones de vidas cada año, lo cual corresponde al 31% de todas las muertes mundiales.*
> *La insuficiencia cardíaca (a veces llamada insuficiencia cardíaca congestiva) es una enfermedad común causada por las ECVs. Esta base de datos contiene 12 variables que pueden ser utilizadas para predecir la mortalidad por insuficiencia cardíaca.*
>
> *La mayoría de las enfermedades cardiovasculares pueden ser prevenidas identificando conductas que puedan suponer factores de riesgo, como el uso del tabaco, una dieta poco saludable y obesidad, inactividad física y alcoholismo; y concienciando a la población de la potencial letalidad de estos actos.*
>
> *Las personas que padezcan alguna enfermedad cardiovascular, o que estén en situación de alto riesgo de padecerlas (debido a la presencia de uno o más factores como hipertensión, diabetes, hiperlipidoses o alguna otra enfermedad ya detectada) necesitan un diagnóstico temprano para comenzar con tratamientos, algo en lo que puede ayudar el diseño de un modelo estadístico.*

La base de datos utilizada consta de 299 elementos (personas sufren de insuficiencia cardíaca congestiva) con 12 variables, más el evento a predecir, que es el fallecimiento o supervivencia del individuo.

Todas las variables son o bien numéricas, o bien binarias. Las binarias toman valor 1 si se cumple lo definido en el nombre de la variable, y valor 0 si no se cumple.

Las variables utilizadas son:

- *age* (variable numérica): Edad de la persona
- *anaemia* (variable binaria): 1 = La persona tiene un nivel bajo de hemoglobina o glóbulos rojos; 0 = La persona tiene un nivel normal de hemoglobina o glóbulos rojos.
- *creatine_phosphokinase* (variable numérica): Nivel de enzima CPK (creatina-fosfoquinasa) en sangre, en µg/L.
- diabetes (variable binaria): 1 = La persona padece diabetes; 0 = La persona no padece diabetes.
- *ejection_fraction* (variable numérica): Mide el porcentaje de sangre que abandona el corazón en cada contracción.
- *high_blood_pressure* (variable booleana): 1 = El paciente tiene hipertensión; 0 = El paciente no tiene hipertensión
- *platelets* (variable numérica): Mide las plaquetas en la sangre de la persona, en kiloplaquetas/mL.
- *serum_creatine* (variable numérica): Mide el nivel de creatinina en la sangre del paciente, en mg/dL.
- *serum_sodium* (variable numérica): Mide el nivel de sodio sérico en la sangre del paciente, en mEq/L.
- *sex* (variable binaria): Sexo del paciente. 1 = Varón; 0 = Mujer.
- *smoking* (variable binaria): 1 = El paciente fuma; 0 = El paciente no fuma.
- *time* (variable numérica): El tiempo, en días, que se realizó un seguimiento al paciente
- *DEATH_EVENT* (variable binaria): Indica si el paciente falleció (1) o sobrevivió (0) a la insuficiencia cardíaca, en el período medido por la variable "time".

Se comprobó que no existiera ningún dato vacío (NA) en la base de datos. También se e los 299 individuos, 96 fallecieron y los otros 203 sobrevivieron.

## 1.2 INTRODUCCIÓN A LAS VARIABLES

En este apartado se procederá a explicar de forma introductoria, algunas de las variables de la base de datos desde un punto de vista médico.

Fuentes:

*Diccionario Médico de Harvard (health.harvard.edu).*
*Biblioteca Nacional de Medicina de los EEUU (nlm.nih.gov).*
*Medicine Net (medicinenet.com).*
*Sociedad Española de Medicina Interna (fesemi.org).*
*Diccionario medico de la Universidad de Salamanca (dicciomed.usal.es).*
*Mayo Clinic (mayoclinic.org)*

Las variables se corresponden con factores normalmente considerados de riesgo para padecer enfermedades cardiovasculares.

- Anemia: Afección por la cual un paciente tiene una cantidad menor de la normal de glóbulos rojos o hemoglobina (la proteína encargada de transportar el oxígeno dentro de los glóbulos rojos). Puede causar algunos síntomas como sensación de debilidad y falta de energía.

- Enzima CPK (Creatina-Fosfoquinasa o Creatinfosfoquinasa): Enzima presente principalmente en los tejidos musculares (incluido el corazón), que se libera a la sangre en altas cantidades si existe daño a alguno de estos músculos.

- Diabetes: Enfermedad metabólica por la cual el cuerpo no produce suficiente insulina, resultando en niveles inusualmente altos de azúcar en la sangre.

- Fracción de eyección: Porcentaje de sangre expulsada del ventrículo izquierdo del corazón con cada contracción. Los niveles normales de fracción de eyección se encontrarían en un rango de entre el 55% y el 70%. Es una medida muy importante del funcionamiento del corazón, lo cual no quiere decir que siempre que la fracción de eyección sea normal, la función del corazón también lo sea. Las causas de una fracción de eyección reducida pueden ser una debilidad del músculo cardíaco, un ataque al corazón reciente o problemas en la válvulas cardíacas.

- Hipertensión: La presión arterial alta es una de las causas más comunes de enfermedades cardiovasculares, y también otras enfermedades como cerebrovasculares o renales. Se considera una presión alta, o hipertensión, cuando la presión sistólica supera los 139 mmHg, o la presión diastólica los 89 mmHg Para que se considere hipertensión tienen que superarse alguna de ellas de forma continuada.

- Plaquetas: Las plaquetas son pequeñas células que ayudan a la coagulación del flujo sanguíneo cuando se produce una ruptura en los vasos circulatorios, para evitar pérdidas masivas de sangre. Un nivel alto de plaquetas es conocido como trombocitosis, aunque normalmente no es una enfermedad en sí misma, sino una consecuencia de alguna infección o condición diferente.

- Creatinina en sangre: La creatinina es un compuesto de deshecho formado durante el metabolismo de la persona. Normalmente es filtrada en los riñones, siendo excretada en la orina. Niveles altos de creatinina son detectados en análisis de orina, o de sangre (creatinina sérica), y pueden servir para detectar enfermedades renales. Niveles de creatinina por encima de 1.35 mg/dL se consideran altos, y por encima de 4 mg/dL pueden ser consecuencia de daños renales graves.

- Sodio en sangre: Niveles bajos o altos de sodio en sangre (hiponatremia e hipernatremia, respectivamente) pueden indicar transtornos renales. Un nivel normal en una persona adulta se encuentra entre 135 y 145 mEq/L. mEq (miliequivalentes) es una milésima parte de un equivalente, unidad utilizada para medir niveles iónicos, y que significa “1 mol de cargas”.

El resto de variables son bastante intuitivas. Por ejemplo, parece lógico que personas de mayor edad tendrán mayor probabilidad de sufrir enfermedades cardiovasculares, o que el hecho de fumar puede tener negativos sobre el funcionamiento circulatorio de la persona.

## 1.3 ESTUDIO PREVIO DE LAS VARIABLES

Para comenzar, se realizará un pequeño estudio de las variables, de forma independiente.

A continuación se presentan algunos valores importantes de las variables numéricas:

***Tabla 1.*** *Valores mínimo, primer cuartil, mediana, media, tercer cuartil y máximo de las variables numéricas de la base de datos.*

| Variable | Mín. | 1ºQ | Mediana | Media | 3ºQ | Máx. |
|---|---|---|---|---|---|---|
| **age** | 40 | 51 | 60 | 60.83 | 70 | 95 |
| **creatine_phosphokinase** | 23 | 116.5 | 250 | 581.8 | 582 | 7861 |
| **ejection_fraction** | 14 | 30 | 38 | 38,08 | 45 | 80 |
| **platelets** | 25100 | 212500 | 262000 | 263358 | 303500 | 850000 |
| **serum_creatinine** | 0.5 | 0.9 | 1.1 | 1.394 | 1.4 | 9.4 |
| **serum_sodium** | 113 | 134 | 137 | 136.6 | 140 | 148 |
| **time** | 4 | 73 | 115 | 130.3 | 203 | 285 |

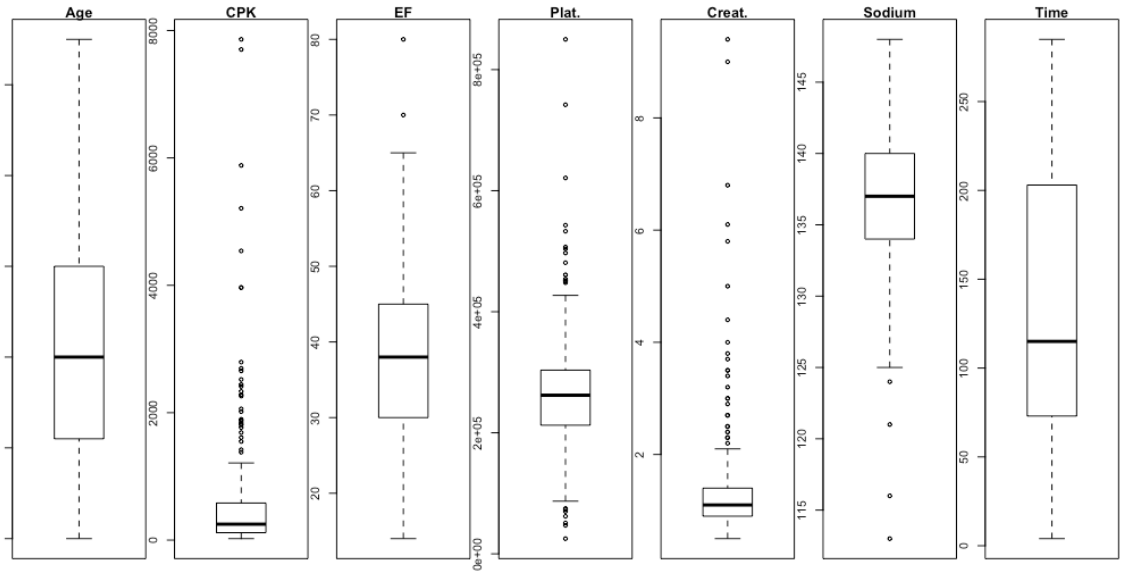


***Figura 1.*** *Diagramas de caja para las variables numéricas. Por orden: Edad, nivel de creatina-fosfoquinasa, fracción de eyección, plaquetas, creatinina, sodio, y tiempo de monitorización.*

De los diagramas de la Figura 1 se pueden sacar algunas conclusiones. El nivel de creatina-fosfoquinasa y el de creatinina siguen una distribución muy asimétrica positiva, con muchos valores muy por encima de la mediana. Por su parte el número de plaquetas sigue una distribución muy extendida, con valores muy lejanos a la mediana tanto por arriba como por debajo; y el nivel de sodio, una distribución asimétrica negativa. Las formas de cada una de las distribuciones se pueden ver mejor en los histogramas de la Figura 2.

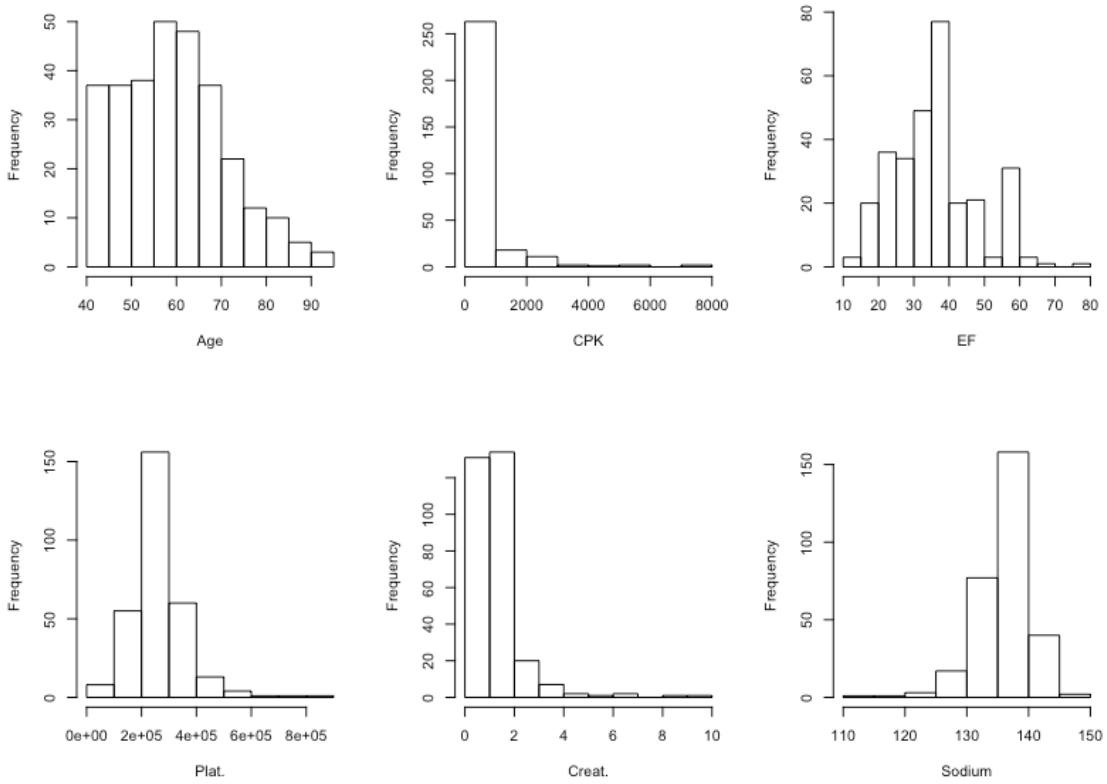


***Figura 2.*** *Histogramas para las variables numéricas. De arriba abajo e izquierda a derecha: Edad, nivel de creatina-fosfoquinasa, fracción de eyección, plaquetas, creatinina y sodio.*

Comparando los valores obtenidos con lo explicado en el apartado 1.2, se pueden obtener algunas conclusiones iniciales. Por ejemplo, se puede comprobar que la mayor parte de los pacientes tienen una fracción de eyección por debajo de la normal. Esto parece obvio, dado que se trata de pacientes de insuficiencia cardíaca. Los niveles de enzima CPK son por lo general muy bajos, con algunas personas con niveles inusualmente elevados.

La variable “time” por sí sola no es muy útil puesto que mide cosas diferentes dependiendo de si el paciente falleció o no. Si éste falleció, mide los días que tardó en morir desde que se comenzó la monitorización. Sin embargo, si no falleció, mide los días a los que se dejó de monitorizar al paciente.

Se analizará, por tanto, la variable “time” para supervivientes y para fallecidos por separado.

***Tabla 2.*** *Resumen de los valores de la variable time de forma separada para supervivientes y fallecidos.*

| Variable | NºElementos | Min. | 1ºQ | Mediana | Media | 3ºQ | Máx. |
|---|---|---|---|---|---|---|---|
| **Supervivientes** | 203 | 12 | 95.0 | 172.0 | 158.30 | 213.00 | 285 |
| **Fallecidos** | 96 | 4 | 25.5 | 44.5 | 70.89 | 102.25 | 241 |

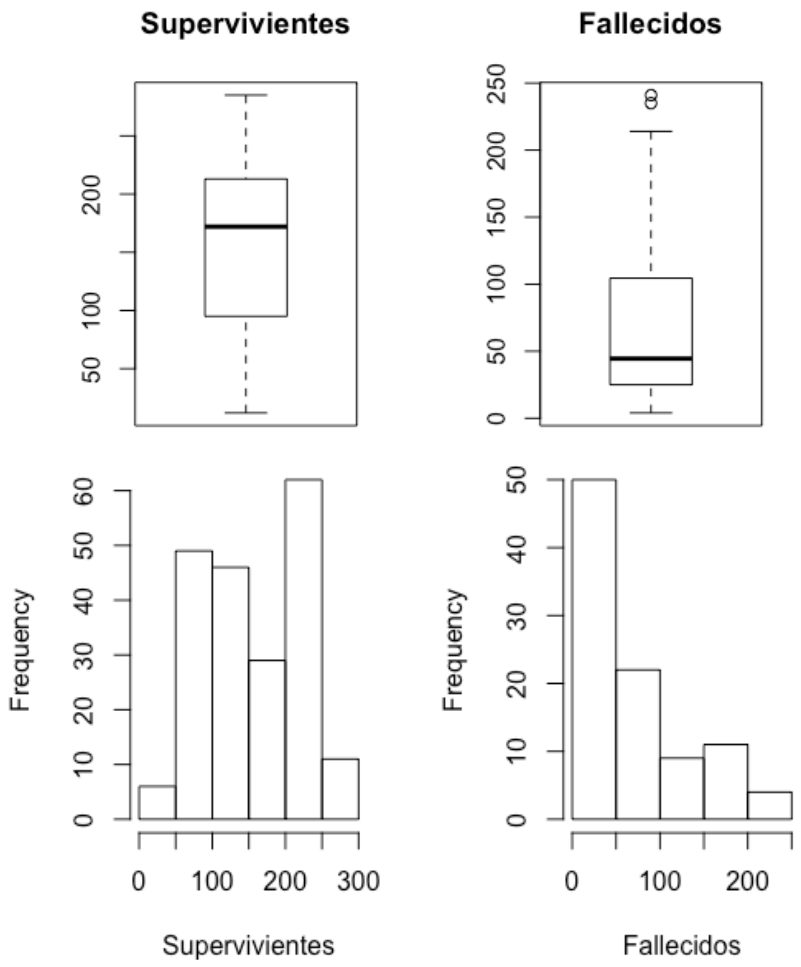


***Figura 3.*** *Diagramas de caja e histogramas para visualizar la diferencia del tiempo de monitorización para supervivientes y fallecidos.*

Como resulta lógico, en general los pacientes fallecidos tuvieron un tiempo de monitorización mucho menor que los que no fallecieron. Las defunciones se produjeron de media 71 días después de comenzar la monitorización, aunque este período se alargó hasta los 245 días. Por su parte, los supervivientes tuvieron un tiempo de monitorización medio de 158 días.

A continuación se analizarán brevemente las variables binarias:

***Tabla 3.*** *Distribución de las variables binarias, en número total, y porcentaje de valores positivos (cuando la variable vale 1).*

| | 0 | 1 | Porcentaje |
|---|---|---|---|
| **Sexo** | 105 | 194 | 64,88% |
| **Anemia** | 170 | 129 | 43,14% |
| **Diabetes** | 174 | 125 | 41,81% |
| **Hipertensión** | 194 | 105 | 35,12% |
| **Fumador** | 203 | 96 | 32,11% |

Se observa que casi dos tercios de los pacientes son hombres. Asimismo, una proporción cercana a la mitad de ellos padece anemia y un porcentaje similar, diabetes. Por otra parte, poco más de un tercio padecen hipertensión, y solo un 32% de ellos fuman.

## 1.4 RELACIONES ENTRE VARIABLES

Calculando los coeficientes de correlación entre todas las variables se puede comprobar si existen dependencias entre variables. De esta forma se puede averiguar si dos variables son demasiado parecidas a la hora de utilizarlas como predictoras. El estadístico elegido para calcular las relaciones entre variables es la R de Pearson. Asimismo, se realizó una gráfica con todas las relaciones entre variables numéricas, para comprobar si se observa algún tipo de relación entre algunas de ellas.

***Tabla 4.*** *Coeficiente R de Pearson para cada par de variables.*

| R de Pearson | Edad | Anemia | CPK | Diabet. | FE | Presión | Plaq. | Creat. | Sodio | Sexo | Fumar | Tiempo | Muerte |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| **Edad** | 1,000 | 0,088 | -0,082 | -0,101 | 0,060 | 0,093 | -0,052 | 0,159 | -0,046 | 0,065 | 0,019 | -0,224 | 0,254 |
| **Anemia** | 0,088 | 1,000 | -0,191 | -0,013 | 0,032 | 0,038 | -0,044 | 0,052 | 0,042 | -0,095 | -0,107 | -0,141 | 0,066 |
| **CPK** | -0,082 | -0,191 | 1,000 | -0,010 | -0,044 | -0,071 | 0,024 | -0,016 | 0,060 | 0,080 | 0,002 | -0,009 | 0,063 |
| **Diabetes** | -0,101 | -0,013 | -0,010 | 1,000 | -0,005 | -0,013 | 0,092 | -0,047 | -0,090 | -0,158 | -0,147 | 0,034 | -0,002 |
| **FE** | 0,060 | 0,032 | -0,044 | -0,005 | 1,000 | 0,024 | 0,072 | -0,011 | 0,176 | -0,148 | -0,067 | 0,042 | -0,269 |
| **Presión** | 0,093 | 0,038 | -0,071 | -0,013 | 0,024 | 1,000 | 0,050 | -0,005 | 0,037 | -0,105 | -0,056 | -0,196 | 0,079 |
| **Plaquetas** | -0,052 | -0,044 | 0,024 | 0,092 | 0,072 | 0,050 | 1,000 | -0,041 | 0,062 | -0,125 | 0,028 | 0,011 | -0,049 |
| **Creat.** | 0,159 | 0,052 | -0,016 | -0,047 | -0,011 | -0,005 | -0,041 | 1,000 | -0,189 | 0,007 | -0,027 | -0,149 | 0,294 |
| **Sodio** | -0,046 | 0,042 | 0,060 | -0,090 | 0,176 | 0,037 | 0,062 | -0,189 | 1,000 | -0,028 | 0,005 | 0,088 | -0,195 |
| **Sexo** | 0,065 | -0,095 | 0,080 | -0,158 | -0,148 | -0,105 | -0,125 | 0,007 | -0,028 | 1,000 | 0,446 | -0,016 | -0,004 |
| **Fumar** | 0,019 | -0,107 | 0,002 | -0,147 | -0,067 | -0,056 | 0,028 | -0,027 | 0,005 | 0,446 | 1,000 | -0,023 | -0,013 |
| **Tiempo** | -0,224 | -0,141 | -0,009 | 0,034 | 0,042 | -0,196 | 0,011 | -0,149 | 0,088 | -0,016 | -0,023 | 1,000 | -0,527 |
| **Muerte** | 0,254 | 0,066 | 0,063 | -0,002 | -0,269 | 0,079 | -0,049 | 0,294 | -0,195 | -0,004 | -0,013 | -0,527 | 1,000 |

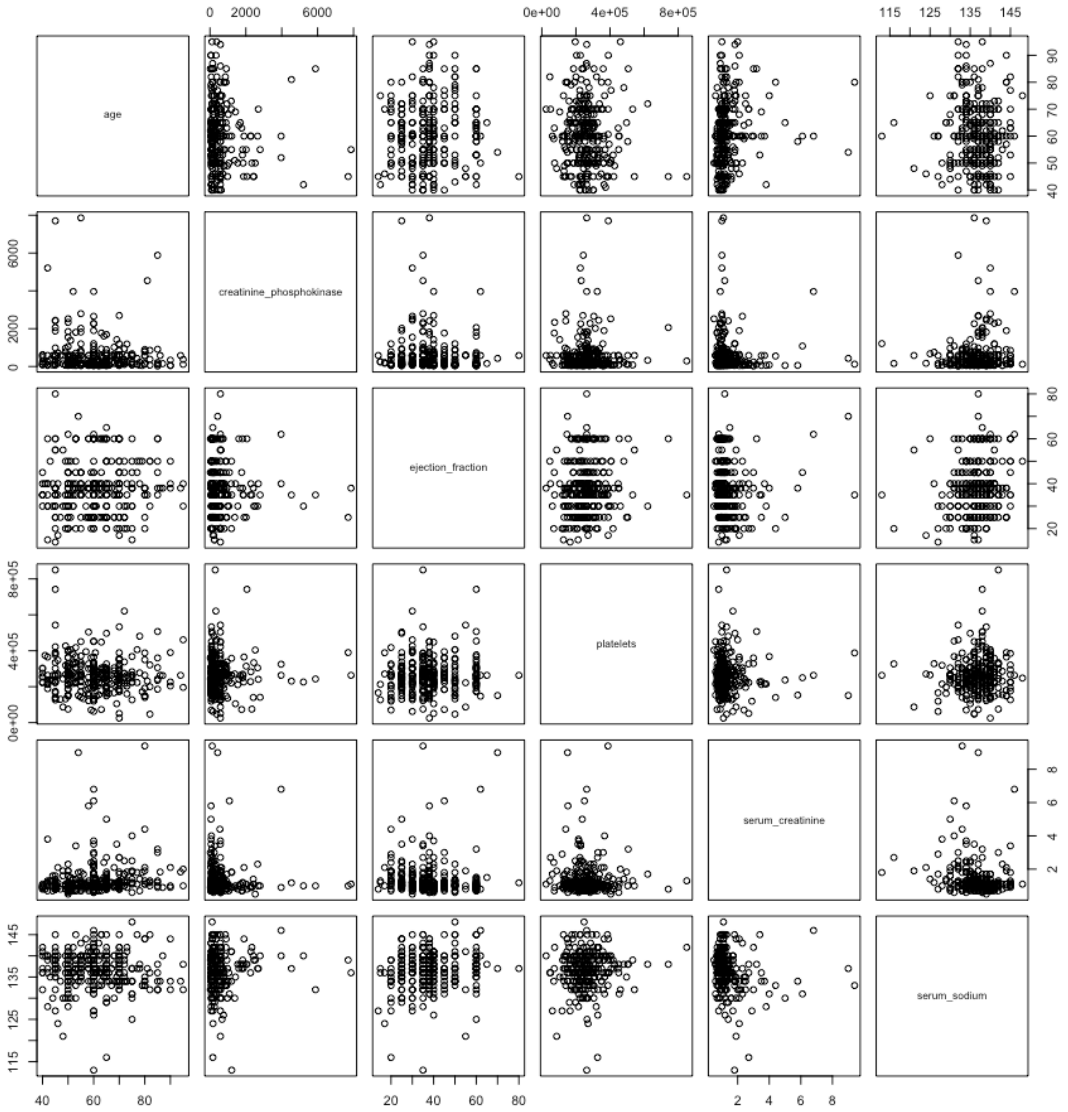


***Figura 4.*** *Diagramas de regresión que muestran la relación entre cada par de variables numéricas de la base de datos.*

Por lo observado en la tabla 4 y la figura 4, ningún par de variables tiene una relación lo suficientemente fuerte como para considerarlas "parecidas" o dependientes. En la tabla 4 el único coeficiente de Pearson superior a 0.5 (en valor absoluto), es la relación entre el tiempo de seguimiento del paciente, y su fallecimiento. El coeficiente es negativo, por lo que la relación sería inversa. Sin embargo, esto no es muy significativo, dado que, como se indicó en el apartado 1.2, la variable time se refiere a cosas distintas según si el paciente falleció o no. Parece lógico, por tanto, que los pacientes que fallecieron tuviesen un menor tiempo de monitorización que en el caso de aquellos que sobrevivieron.

En cuanto a la relación con la muerte del individuo, las variables que más parecen afectar son el nivel de creatinina en sangre, la fracción de eyección en sentido inverso, es decir, bajas fracciones de eyección favorecen la muerte; y la edad.

Por las razones citadas con anterioridad, la variable “time” no se tendrá en cuenta a la hora de construir el modelo, dado que parece obvio que su valor es más bien consecuencia y no causa del fallecimiento del paciente.

# 2. APLICACIÓN DE UN ALGORITMO RANDOM FOREST

## 2.1 EL ALGORITMO RANDOM FOREST

Para resolver el problema, vamos a utilizar un algoritmo Random Forest, que permitirá modelizar las muertes causadas por insuficiencia cardíaca en función de las variables dadas. Este modelo podrá ser utilizado para predecir los resultados de pacientes en el futuro, y pueden servir para prevenir fallecimientos por esta causa.

Este algoritmo construye árboles (a su vez construidos mediante el algoritmo CART) a partir de la base de datos. En lugar de utilizar todos los datos para la construcción de los árboles, se utiliza solo una parte de ellos, conformando el resto los datos OOB (“out of bag”). Entonces, los datos OOB se comparan con el árbol CART para ser categorizados. El resultado final de cada dato es, una vez realizados un numero determinado de árboles CART con muestras aleatorias, se calcula la media del resultado de todas las veces que fue OOB, o en caso de ser una variable categórica, se asocia el dato a la categoría que más veces se haya repetido cuando fue OOB.

## 2.2 PARÁMETROS DEL RANDOM FOREST

El número de árboles realizados en el algoritmo Random Forest deberá ser lo suficientemente grande para que todos los datos sean out-of-bag suficientes veces como para que el resultado medio sea significativo. En el caso que nos ocupa, el número de árboles CART diferentes que se realizarán en el algoritmo será 1000.

Se ha de decidir, asimismo, la cantidad de variables que seleccionarán en cada partición del árbol CART (valor mtry). Para ello, se ha creado un bucle para calcular el error OOB para cada valor mtry posible. Nótese que el valor máximo de mtry es igual al número de variables de los datos, en este caso 12.

***Tabla 5.*** *Valores del error "out-of-bag" para cada valor posible del número de variables seleccionadas en cada nodo del árbol.*

| mtry | Error OOB |
|---|---|
| **1** | 0.1784501 |
| **2** | 0.1683873 |
| **3** | 0.1697447 |
| **4** | 0.1709781 |
| **5** | 0.1711722 |
| **6** | 0.1738472 |
| **7** | 0.1730197 |
| **8** | 0.1744171 |
| **9** | 0.1744165 |
| **10** | 0.1759795 |
| **11** | 0.1776357 |
| **12** | 0.1782158 |

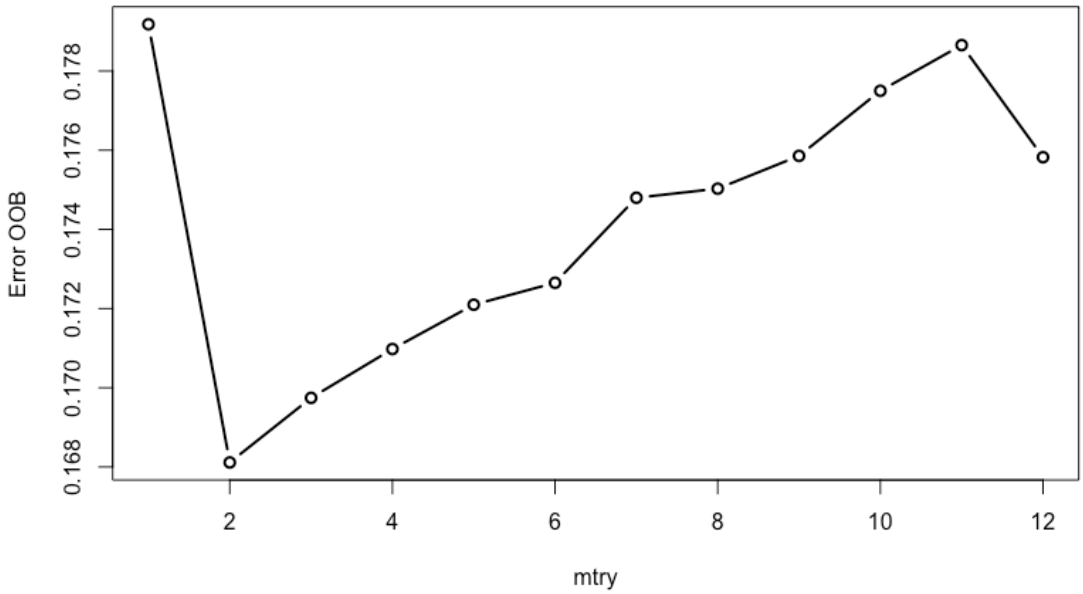


***Figura 5.*** *Representación del error "out-of-bag" en función del número de variables seleccionadas en cada nodo del árbol.*

El valor de mtry que minimiza el error out-of-bag del algoritmo random forest es 2 (con una tasa de error de 0.168). Por tanto, este es el valor que se utilizará en nuestro algoritmo.

## 2.3 APLICACIÓN DEL ALGORITMO RANDOM FOREST

Se aplicó sobre los datos el algoritmo Random Forest, con los parámetros elegidos en el apartado 2.2. El error out-of-bag obtenido tras 1000 árboles es de 0.170, mientras que el porcentaje de varianza explicado por el algoritmo asciende al 22.16%. La siguiente gráfica muestra el error out-of-bag medio en función del número de árboles que conforman el bosque:

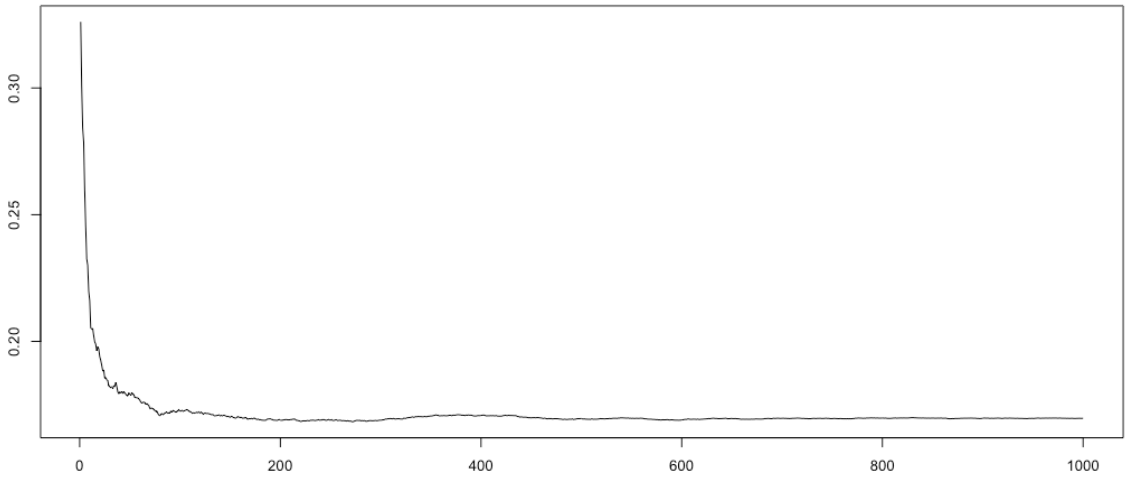


***Figura 6.*** *Error OOB medio en función del número de árboles calculados mediante el algoritmo Random Forest.*

Se puede observar cómo el error se estabiliza en forma de asíntota horizontal en torno al valor final de 0.170. Como se puede ver, realmente no era necesario realizar 1000 árboles dado que el error ya es bastante estable a partir de 200 árboles aproximadamente.

Posteriormente, se calculó la importancia de cada variable a la hora de predecir la muerte del individuo.

La primera de las medidas de importancia utilizadas es el %IncMSE, que mide el porcentaje de incremento del error cuadrado (MSE = Mean Squared Error) cuando la variable es excluida del modelo. Por tanto, cuanto más grande sea este valor, más importante será la variable para el modelo. Por su parte, el incremento de la pureza del nodo (IncNodePurity) mide cuánto se divide en un nodo la variable predecida cuando utilizamos cada variable predictora para efectuar la división. Estas medidas se presentan en la tabla 6, y las figuras 7 y 8.

***Tabla 6.*** *Medidas de importancia de las variables en el modelo random forest desarrollado*

| Variable | %IncMSE | Node Purity |
|---|---|---|
| **Edad** | 15,28 | 7,88 |
| **Anemia** | -2,36 | 1,14 |
| **CPK** | 1,86 | 6,77 |
| **Diabetes** | 0,07 | 1,05 |
| **Fr. Eyección** | 30,31 | 9,56 |
| **Presión elevada** | -1,17 | 1,21 |
| **Plaquetas** | 2,80 | 6,62 |
| **Creatinina** | 29,89 | 10,89 |
| **Sodio** | 8,99 | 6,13 |
| **Sexo** | 5,71 | 1,10 |
| **Fumador** | 4,48 | 1,05 |

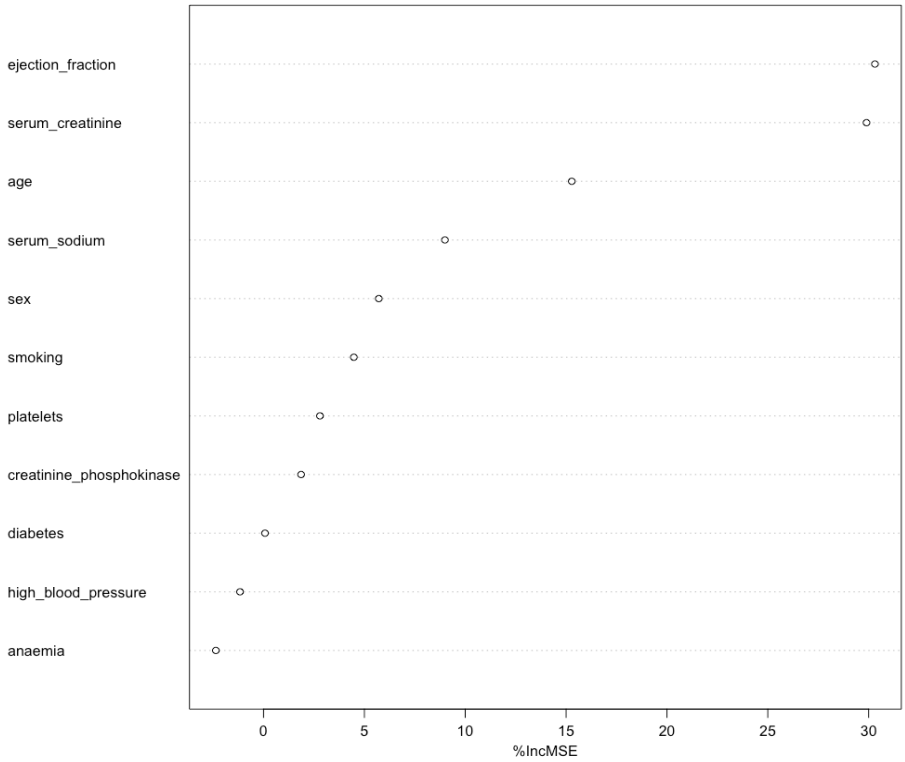


***Figura 7.*** *Medidas del porcentaje de incremento del error para cada una de las variables del modelo, ordenadas por importancia*

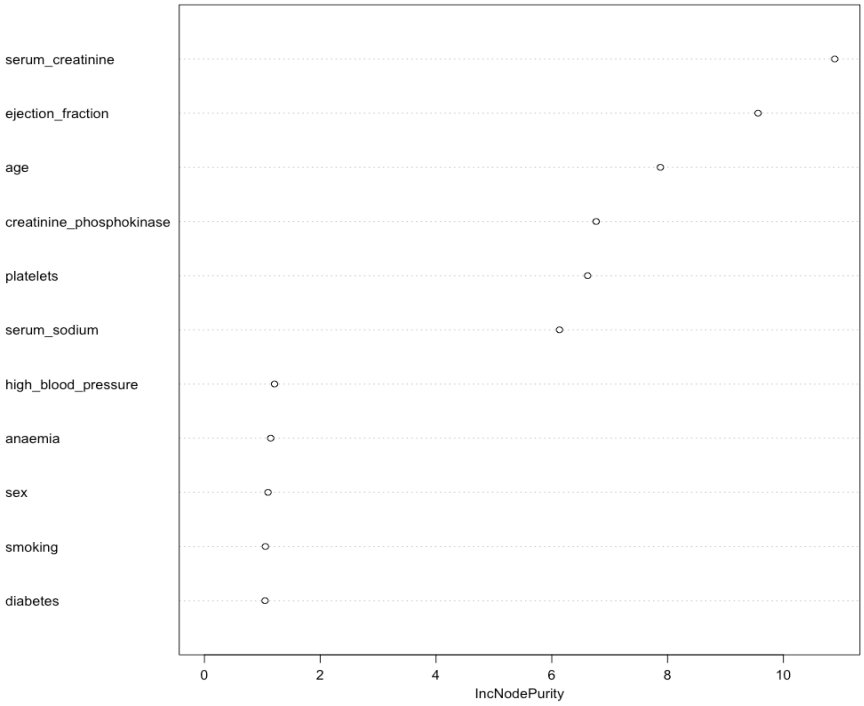


***Figura 8.*** *Medidas del incremento de la pureza del nodo para cada una de las variables del modelo, ordenadas por importancia.*

Se calculó también el número de veces que cada uno de los datos fue "out-of-bag". Este número estuvo siempre en el rango comprendido entre 319 y 408 veces, con una media de 367.2, y una mediana de 368, lo cual podemos considerar un número suficiente para obtener unos resultados satisfactorios.

Por último, se calculó el número de nodos terminales para cada árbol del bosque. A continuación se presentan un resumen y un histograma del número de nodos terminales de los 1000 árboles:

***Tabla 7.*** *Resumen del número de nodos terminales de los árboles CART.*

| Mín | 1ºQ | Mediana | Media | 3ºQ | Máx |
|---|---|---|---|---|---|
| 42.00 | 80.00 | 84.00 | 83.14 | 88.00 | 102.00 |

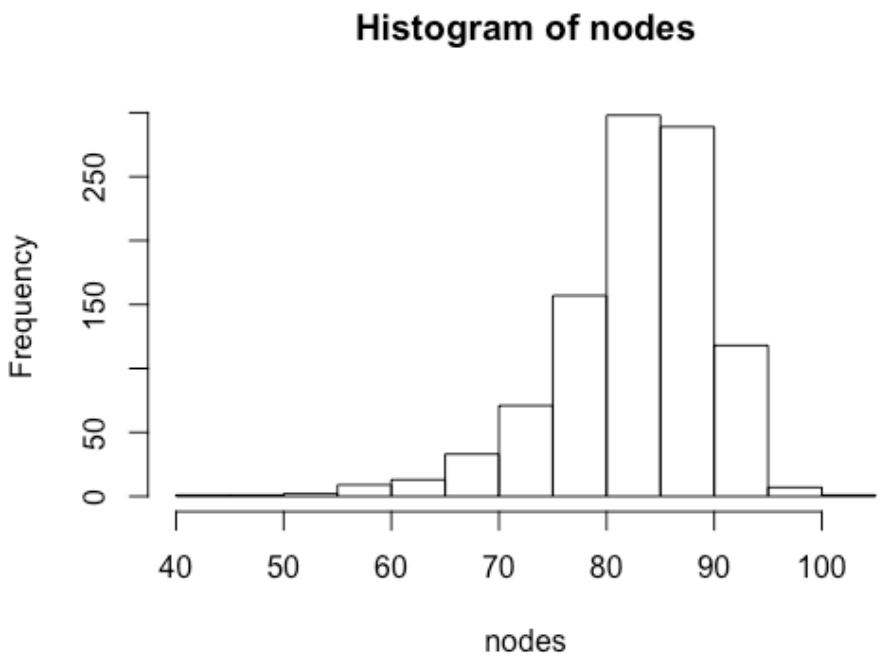


***Figura 9.*** *Histograma del número de nodos terminales de los árboles CART.*

El número de nodos terminales osciló entre 42 y 102. Como se puede ver en el histograma, la mayoría de estos árboles tuvieron entre 80 y 90 nodos terminales, y muy pocos por debajo de 60, siendo el mínimo de 42 una anomalía. Esto muestra que la complejidad de los árboles fue en general bastante alta, algo que no debería de sorprender dado que se trabajó con 12 variables.

# 3. INTERPRETACIÓN DE LOS RESULTADOS

## 3.1 INTERPRETACIÓN DE LO OBTENIDO MEDIANTE EL ALGORITMO RANDOM FOREST

Con lo visto en la tabla 6 y las figuras 7 y 8 se pueden inferir algunas conclusiones. Hay algunas variables que afectan significativamente al resultado de las predicciones. Las dos que afectan fundamentalmente al desenlace de la enfermedad, con una importancia similar, son la edad y el nivel de creatinina en la sangre. La tercera variable en importancia sería la edad, y la cuarta, el nivel de sodio en sangre.

La única de las variables binarias que tienen un incremento del error medio superior al 5% es el sexo, siendo más probable el fallecimiento en hombres que en mujeres. Sin embargo, esto podría no ser muy significativo dada la gran desigualdad entre el tamaño muestral de hombres y de mujeres, visto en el apartado 1.3. El resto de las variables tienen un incremento del error inferior al 5%, por lo que no parece que afecten en gran medida al fallecimiento o supervivencia de los enfermos de insuficiencia cardíaca.

El resultado obtenido de que una de las dos variables más importantes sea la fracción de eyección parece bastante lógico, dado que cuanto menor sea esta fracción, mayor será la severidad de la insuficiencia cardíaca de la que padece la persona. La creatinina alta es la otra variable más importante. Esto muestra la relación existente entre enfermedades renales y cardiovasculares. También constata esta relación el hecho de que el nivel de sodio en sangre también sea otro de los factores más importantes para predecir la mortalidad. Por su parte, es más intuitivo que la edad avanzada también afecte negativamente al transcurso de la enfermedad.

El hecho de que alguno de los factores más considerados como "de riesgo" no influyan prácticamente en la muerte del paciente puede deberse a distintas causas. La principal puede ser que sean factores de riesgo para contraer la enfermedad, pero una vez contraída, no afecten al desenlace de dicha enfermedad. Por ejemplo, factores como la anemia, diabetes, hipertensión o si el paciente fuma, pueden ser causantes de enfermedades del corazón, pero, al menos en este caso, no parecen tener una gran influencia en si el paciente supera o no dicha enfermedad. Dicho de otra forma, estas variables servirían para predecir la morbilidad, pero no la mortalidad debido a esta enfermedad concreta.

Otro caso que llama la atención es el de la enzima creatinina-fosfoquinasa, cuyos niveles elevados en sangre suelen ser resultado de graves daños en los tejidos musculares del individuo, principalmente del corazón, y, sin embargo, no parece tener mucha importancia para predecir la muerte del individuo una vez que ha contraído la insuficiencia cardíaca.

Nótese que las cuatro variables más importantes coinciden con las variables con un mayor coeficiente de regresión de Pearson comparados con la variable DEATH_EVENT en la tabla 4.

## 3.2 EJEMPLO DE UTILIZACIÓN DEL MODELO COMO PREDICTOR

Se crearon cuatro pacientes ficticios, utilizando para las variables los valores redondeados de los cuartiles de los pacientes de la base de datos original, más uno aleatorio de la siguiente forma. El paciente #1 tiene los datos del cuartil más "positivo" dependiendo de la variable, por ejemplo, niveles altos de creatinina resultaron en mayor probabilidad de muerte, mientras que niveles altos de sodio suponen mayor probabilidad de supervivencia. De la misma manera, el paciente #3 tomó los datos del cuartil con peor diagnóstico, y el paciente #2, los datos de la mediana. El paciente #4 toma datos introducidos de forma aleatoria.

Se aplicó el modelo calculado a estos nuevos datos para predecir las probabilidades de muerte de los cuatro pacientes.

***Tabla 8.*** *Valores de las variables para dos nuevos datos creados para probar el modelo como predictor, y predicción obtenida.*

| **Paciente** | **#1** | **#2** | **#3** | **#4** |
|---|---|---|---|---|
| **Edad** | 51 | 60 | 70 | 64 |
| **Anemia** | 0 | 0 | 1 | 1 |
| **CPK** | 117 | 250 | 582 | 280 |
| **Diabetes** | 0 | 0 | 1 | 0 |
| **Fr. Eyección** | 45 | 38 | 30 | 40 |
| **Presión** | 0 | 0 | 1 | 0 |
| **Plaquetas** | 303500 | 262000 | 212500 | 208000 |
| **Creatinina** | 0,9 | 1,1 | 1,4 | 1,25 |
| **Sodio** | 140 | 137 | 134 | 138 |
| **Sexo** | 0 | 1 | 1 | 0 |
| **Fumador** | 0 | 0 | 0 | 1 |
| **Probabilidad de fallecimiento** | **5.888%** | **9.792%** | **42.896%** | **17.926%** |

Como parece lógico, los datos del tercer cuartil son los que tienen más probabilidades de fallecimiento.

## 3.3 CONCLUSIONES

Dentro de los factores que se calcularon más importantes, la edad no es un factor que se pueda controlar, y parece sensato no tratar a los pacientes de diferentes edades de igual manera.

Habrá de tenerse en cuenta, por ejemplo, que la fracción de eyección, útil para diagnosticar la enfermedad, también es un buen baremo de la severidad y el riesgo de la misma.

Algo que se comprobó de forma bastante evidente, fue la relación entre los fallecimientos por insuficiencia cardíaca y enfermedades renales. Tanto los niveles de sodio en sangre, como los de creatinina en sangre, sirven para calibrar de forma general el buen funcionamiento de los riñones, y niveles peligrosos de estos baremos demostraron tener efectos muy negativos en cuanto al desenlace de las insuficiencias cardíacas (ha de aclararse que los niveles peligrosos de creatinina son altos, mientras que los de sodio son bajos). Por tanto, conviene extremar especialmente las precauciones en pacientes con problemas renales cuando contraigan enfermedades cardiovasculares y viceversa, puesto que los factores relacionados con un mal funcionamiento del aparato excretor conllevan un aumento significativo de los fallecimientos de los pacientes de enfermedades del corazón.

# 4. BIBLIOGRAFÍA

Relación de páginas web, libros y documentos utilizados en este trabajo:


- Kaggle (kaggle.com)
- Diccionario Médico de Harvard (health.harvard.edu)
- Biblioteca Nacional de Medicina de los EEUU (nlm.nih.gov)
- Medicine Net (medicinenet.com)
- Sociedad Española de Medicina Interna (fesemi.org)
- Diccionario medico de la Universidad de Salamanca (dicciomed.usal.es)
- Mayo Clinic (mayoclinic.org)
- Liaw, A., Wiener, M. (2002). *Classification and Regression by randomForest.* R News.Vol. 2/3, December 2002, pp. 18-22.
- Strobl, C., Malley, J., Tutz, G. (2009). *An Introduction to Recursive Partitioning.* Technical Report Number 55, 2009, Department of Statistics, University of Munich.
- Berk, Richard A. (2005). *An Introduction to Ensemble Methods for Data Analysis.* Department of Statistics, UCLA, March 27, 2005.
- Elosua, Paula (2011). *Introducción al entorno R.* ©Servicio Editorial de la Universidad del País Vasco.
- Arriaza Gómez, A. J., Fernández Palacín, F., López Sánchez, M. A., Muñoz Márquez, M., Pérez Plaza, S., Sánchez Navas, A. (2008). *Estadística Básica con R y R-commander.* Universidad de Cádiz.
- Hewson, Paul J. (2009). *Multivariate Statistics with R.* ©Paul Hewson
- Manly, Bryan F.J., Navarro Alberto, Jorge A. (2017). *Multivariate Statistical Methods: A Primer (Fourth Edition).* CRC Press, Taylor & Francis Group.